




ANÁLISIS DEL IMPACTO DEL
SUBMUESTREO DEL ESPACIO-K EN
LA SEGMENTACIÓN DE IMÁGENES
DE RESONANCIA MAGNÉTICA
MEDIANTE MEDSAM

DESCRIPCIÓN BREVE

Este trabajo analiza cómo el submuestreo del espacio-k, utilizado para acelerar la adquisición en resonancia magnética, afecta a la calidad de la segmentación automática de imágenes médicas. Para ello, se implementa un pipeline completo que incluye simulación en el dominio de frecuencias, reconstrucción de imagen y segmentación mediante el modelo MedSAM. El estudio combina datos sintéticos y reales (BraTS 2020), evaluando el impacto de distintas estrategias de submuestreo mediante el coeficiente Dice.

MARTÍNEZ CAZAUX, MAURO
MARTÍNEZ MANRESA, JAVIER
MUÑOZ VERA, JAVIER

Ciencia e Ingeniería de Datos, Universidad
Politécnica de Cartagena. Curso 2025/26

ÍNDICE

1. Introducción.....	3
1.1. Contexto del problema	3
1.2. Motivación del estudio.....	3
1.3. Objetivo general.....	3
1.4. Objetivos específicos	3
1.5. Estructura de la memoria	4
2. Fundamentos teóricos	5
2.1. Resonancia magnética y espacio-k	5
2.2. Submuestreo del espacio-k y aceleración de adquisición	5
2.3. Reconstrucción de imagen mediante FFT e IFFT	5
2.4. Segmentación asistida por inteligencia artificial en imagen médica	6
2.5. Modelo MedSAM.....	6
2.6. Métrica de evaluación: coeficiente Dice.....	6
3. Datos y materiales utilizados.....	7
3.1. Fantasma de Shepp-Logan.....	7
3.2. Dataset BraTS 2020	7
3.3. Selección de slices y pacientes	8
3.4. Entorno y librerías empleadas.....	8
4. Diseño general del pipeline	9
4.1. Descripción global del flujo de trabajo	9
4.2. Fase 1: Validación técnica inicial sobre Shepp-Logan	9
4.3. Fase 2: Generación de escenarios de submuestreo	9
4.4. Fase 3: Validación de segmentación en BraTS 2020.....	10
4.5. Fase 4: Análisis multi-slice y multi-paciente	10
5. Implementación del pipeline	11
5.1. Carga y preprocesado de imágenes	11
5.2. Transformación al espacio-k.....	11
5.3. Generación de máscaras de submuestreo	11
5.3.1. Submuestreo cartesiano uniforme	11
5.3.2. Submuestreo cartesiano no uniforme	12
5.3.3. Partial Fourier	12
5.4. Reconstrucción de imágenes submuestreadas.....	12
5.5. Generación de prompts para MedSAM.....	12
5.6. Segmentación con MedSAM	13

5.7.	Cálculo del coeficiente Dice.....	13
5.8.	Organización experimental del código y automatización de pruebas.....	13
6.	Desarrollo experimental	14
6.1.	Experimento 1: integración del pipeline en Shepp-Logan	14
6.2.	Experimento 2: efecto visual del submuestreo en Shepp-Logan	14
6.3.	Experimento 3: validación base de MedSAM sobre una slice BraTS original... 14	
6.4.	Experimento 4: impacto del submuestreo en una slice BraTS	15
6.5.	Experimento 5: extensión a múltiples slices del mismo paciente.....	15
6.6.	Experimento 6: análisis multi-paciente.....	16
7.	Resultados	16
7.1.	Resultados cualitativos de reconstrucción	16
7.2.	Resultados cualitativos de segmentación	17
7.3.	Resultados cuantitativos en Shepp-Logan	19
7.4.	Resultados cuantitativos en BraTS: una slice	19
7.5.	Resultados cuantitativos en BraTS: múltiples slices.....	20
7.6.	Resultados globales multi-paciente	20
7.7.	Comparación entre Dice respecto a GT y dice respecto a la segmentación original de MedSAM.....	21
8.	Discusión	22
8.1.	Influencia del submuestreo en la reconstrucción	22
8.2.	Influencia del submuestreo en la segmentación	23
8.3.	Comportamientos no monótonos observados.....	23
8.4.	Posible efecto de regularización por pérdida de alta frecuencia	23
8.5.	Diferencias entre submuestreo uniforme, no uniforme y partial Fourier	24
8.6.	Variabilidad entre slices y pacientes	24
8.7.	Limitaciones del estudio	24
9.	Conclusiones	25
9.1.	Conclusiones principales	25
9.2.	Respuesta a los objetivos planteados.....	25
9.3.	Líneas futuras de trabajo	26
10.	Bibliografía	26

1. Introducción

1.1. Contexto del problema

La resonancia magnética (RM) es una de las técnicas de imagen médica más utilizadas en el diagnóstico clínico, debido a su capacidad para proporcionar imágenes de alta resolución y gran contraste entre tejidos blandos sin el uso de radiación ionizante. Sin embargo, uno de sus principales inconvenientes es el tiempo de adquisición, que puede resultar elevado y afectar tanto a la comodidad del paciente como a la eficiencia del sistema sanitario.

Una de las estrategias más utilizadas para reducir el tiempo de adquisición consiste en el submuestreo del espacio de frecuencias, conocido como espacio-k. Este enfoque permite acelerar la captura de datos, pero introduce degradaciones en la imagen reconstruida que pueden afectar a su calidad visual y, potencialmente, a tareas posteriores de análisis automático.

En los últimos años, los modelos de inteligencia artificial han demostrado un gran potencial en tareas de segmentación de imágenes médicas. En particular, modelos como MedSAM permiten generar segmentaciones a partir de información visual con un alto grado de automatización. Sin embargo, estos modelos suelen evaluarse sobre imágenes de alta calidad, sin considerar de forma sistemática el impacto de degradaciones derivadas del proceso de adquisición

1.2. Motivación del estudio

En un contexto clínico real, es frecuente que las imágenes médicas no presenten una calidad óptima debido a restricciones en el tiempo de adquisición o a limitaciones técnicas. Esto plantea una cuestión relevante:

¿Cómo afectan estas degradaciones a los modelos de segmentación basados en inteligencia artificial?

En particular, el submuestreo del espacio-k introduce una pérdida de información, especialmente en las componentes de alta frecuencia, lo que puede alterar la apariencia de la imagen. Este cambio puede tener efectos no triviales sobre el comportamiento de los modelos de segmentación, que dependen de patrones visuales para delimitar estructuras anatómicas.

La motivación principal de este trabajo es estudiar de forma sistemática esta relación, analizando no solo si el submuestreo degrada la segmentación, sino también si existen configuraciones en las que su efecto sea más complejo o incluso beneficioso en determinados casos.

1.3. Objetivo general

El objetivo principal de este trabajo es analizar el impacto del submuestreo del espacio-k en la calidad de la segmentación de imágenes médicas mediante el modelo MedSAM, evaluando cómo diferentes estrategias de adquisición afectan al resultado final.

1.4. Objetivos específicos

Para alcanzar el objetivo general, se plantean los siguientes objetivos específicos:

- Implementar un pipeline completo de procesamiento de imágenes en resonancia magnética, incluyendo:
 - Transformación al espacio-k mediante FFT.
 - Aplicación de técnicas de submuestreo.
 - Reconstrucción de imagen mediante IFFT.
- Diseñar y aplicar distintos esquemas de submuestreo:
 - Submuestreo cartesiano uniforme.
 - Submuestreo cartesiano no uniforme.
 - Técnicas de Partial Fourier.
- Integrar el modelo MedSAM en el pipeline para realizar segmentación sobre las imágenes reconstruidas.
- Evaluar cuantitativamente la calidad de las segmentaciones mediante el coeficiente Dice, considerando:
 - Comparación frente a la máscara real (ground truth).
 - Comparación frente a la segmentación obtenida en la imagen original.
- Analizar el comportamiento del sistema en:
 - Datos sintéticos (fantoma de Shepp-Logan) para validación técnica.
 - Datos reales (BraTS 2020) para evaluación en escenarios clínicos.
- Extender el análisis a múltiples slices y múltiples pacientes con el fin de estudiar la consistencia de los resultados.

1.5. Estructura de la memoria

La memoria se organiza de la siguiente manera:

- En el Capítulo 2 se presentan los fundamentos teóricos necesarios, incluyendo el concepto de espacio-k, técnicas de submuestreo, reconstrucción de imágenes y modelos de segmentación.
- En el Capítulo 3 se describen los datos utilizados y el entorno de trabajo.
- En el Capítulo 4 se expone el diseño general del pipeline desarrollado.
- En el Capítulo 5 se detalla la implementación técnica de cada una de las fases del sistema.
- En el Capítulo 6 se describen los experimentos realizados.
- En el Capítulo 7 se presentan los resultados obtenidos.
- En el Capítulo 8 se realiza un análisis crítico de los resultados.
- Finalmente, en el Capítulo 9 se recogen las conclusiones y posibles líneas futuras de trabajo.

2. Fundamentos teóricos

2.1. Resonancia magnética y espacio-k

La resonancia magnética (RM) es una técnica de adquisición de imágenes que se basa en la respuesta de los protones del cuerpo humano ante un campo magnético y señales de radiofrecuencia. A diferencia de otras modalidades, la RM no adquiere directamente la imagen en el dominio espacial, sino que registra información en el denominado espacio de frecuencias, conocido como espacio-k.

El espacio-k representa la imagen en términos de componentes frecuenciales. Cada punto del espacio-k contiene información global de la imagen, y la distribución de estas frecuencias determina la apariencia final tras su reconstrucción. En particular:

- Las bajas frecuencias contienen la información estructural global (formas, intensidades generales).
- Las altas frecuencias aportan detalles finos y bordes.

La imagen en el dominio espacial se obtiene aplicando una transformada inversa sobre el espacio-k, lo que establece una relación directa entre la adquisición en frecuencia y la calidad visual final.

2.2. Submuestreo del espacio-k y aceleración de adquisición

El proceso de adquisición completo del espacio-k puede ser costoso en tiempo. Para reducir este tiempo, es habitual emplear técnicas de submuestreo, que consisten en adquirir solo una parte de las muestras del espacio-k.

El submuestreo permite definir un factor de aceleración (R), que indica cuánto se reduce el número de datos adquiridos respecto al caso completo. Sin embargo, esta reducción implica una pérdida de información que puede traducirse en artefactos o degradación en la imagen reconstruida.

Existen distintas estrategias de submuestreo, entre las que destacan:

- Submuestreo cartesiano uniforme: se adquieren líneas del espacio-k de forma periódica.
- Submuestreo cartesiano no uniforme: se prioriza la adquisición de ciertas regiones, típicamente las bajas frecuencias.
- Partial Fourier: se adquiere solo una fracción del espacio-k, aprovechando ciertas propiedades de simetría.

Cada una de estas estrategias implica un compromiso distinto entre velocidad de adquisición y calidad de la imagen.

2.3. Reconstrucción de imagen mediante FFT e IFFT

La relación entre el espacio-k y la imagen en el dominio espacial se establece mediante la transformada de Fourier. En el caso de imágenes digitales, esta transformación se implementa mediante la Fast Fourier Transform (FFT) y su inversa (IFFT).

- La FFT permite transformar una imagen del dominio espacial al dominio frecuencial (espacio-k).
- La IFFT permite reconstruir la imagen a partir de los datos del espacio-k.

En condiciones ideales, si se dispone de la totalidad del espacio-k, la reconstrucción es fiel a la imagen original. Sin embargo, cuando se aplica submuestreo, la reconstrucción se realiza con información incompleta, lo que puede generar artefactos como aliasing o pérdida de detalle.

Este proceso es clave en el pipeline, ya que conecta directamente las decisiones de adquisición (submuestreo) con la calidad de la imagen que posteriormente será analizada.

2.4. Segmentación asistida por inteligencia artificial en imagen médica

La segmentación de imágenes médicas consiste en identificar y delimitar regiones de interés, como órganos o lesiones, dentro de una imagen. Tradicionalmente, esta tarea se realizaba de forma manual, lo que implica un alto coste en tiempo y variabilidad entre expertos.

Los modelos de inteligencia artificial han permitido automatizar este proceso mediante el aprendizaje de patrones visuales. Estos modelos reciben como entrada una imagen y producen una máscara que indica la localización de la estructura de interés.

El rendimiento de estos modelos depende en gran medida de la calidad de la imagen de entrada. Cambios en la resolución, el contraste o la presencia de artefactos pueden afectar significativamente a su capacidad para generar segmentaciones precisas.

2.5. Modelo MedSAM

MedSAM es una adaptación del modelo Segment Anything Model (SAM) al ámbito de la imagen médica. Este tipo de modelos se basa en una arquitectura capaz de generar segmentaciones a partir de una imagen y una señal de guía o prompt, como un punto o una caja delimitadora.

En este trabajo, el modelo se utiliza en combinación con un box prompt, que proporciona una región aproximada donde se encuentra la estructura de interés. A partir de esta información, el modelo genera una máscara binaria que representa la segmentación.

Una característica relevante de este enfoque es que la calidad de la segmentación no depende únicamente del modelo, sino también de la calidad de la imagen de entrada. Por tanto, resulta especialmente adecuado para estudiar cómo las degradaciones en la imagen afectan al resultado final.

2.6. Métrica de evaluación: coeficiente Dice

Para evaluar la calidad de las segmentaciones, se utiliza el coeficiente Dice, una métrica ampliamente empleada en segmentación de imágenes médicas.

El coeficiente Dice mide el grado de solapamiento entre dos máscaras binarias, típicamente la segmentación obtenida por el modelo y una referencia (ground truth). Su valor oscila entre 0 y 1:

- Un valor de 1 indica coincidencia perfecta.

- Un valor de 0 indica ausencia total de solapamiento.

El coeficiente Dice permite cuantificar de forma objetiva las diferencias entre segmentaciones, siendo especialmente útil para comparar el rendimiento del modelo bajo distintas condiciones de adquisición.

3. Datos y materiales utilizados

3.1. Fantasma de Shepp-Logan

El fantoma de Shepp-Logan es una imagen sintética ampliamente utilizada en el ámbito del procesamiento de imágenes médicas, especialmente en estudios relacionados con reconstrucción en tomografía y resonancia magnética.

Se trata de una representación idealizada de una sección del cerebro, compuesta por regiones elípticas con diferentes intensidades. Su principal ventaja es que permite trabajar en un entorno completamente controlado, donde la estructura de la imagen es conocida y no está afectada por ruido clínico ni variabilidad anatómica.

En este trabajo, el fantoma de Shepp-Logan se ha utilizado con el objetivo de:

- Validar el funcionamiento técnico del pipeline de transformación al espacio-k y reconstrucción mediante FFT e IFFT.
- Analizar de forma visual el efecto de las distintas estrategias de submuestreo sobre la imagen reconstruida.
- Comprobar la correcta implementación de las máscaras de submuestreo antes de aplicarlas a datos reales.

El uso de este fantoma permite aislar el comportamiento del sistema sin introducir la complejidad propia de las imágenes médicas reales, facilitando así la validación inicial del pipeline.

3.2. Dataset BraTS 2020

Para la evaluación en un entorno realista se ha utilizado el dataset BraTS 2020 (Brain Tumor Segmentation Challenge), uno de los conjuntos de datos más utilizados en el ámbito de la segmentación de tumores cerebrales.

Este dataset contiene estudios de resonancia magnética de pacientes con tumores cerebrales, junto con segmentaciones manuales realizadas por expertos. Cada caso incluye diferentes modalidades de imagen, como FLAIR, T1 o T2, así como un volumen de segmentación donde se etiquetan las regiones tumorales.

En este trabajo se ha empleado:

- Una modalidad de imagen por paciente (preferentemente FLAIR).
- El volumen de segmentación asociado, a partir del cual se ha generado una máscara binaria que identifica la presencia de tumor.

A diferencia del fantoma sintético, el dataset BraTS introduce:

- Variabilidad anatómica entre pacientes.

- Diferencias en tamaño, forma y localización del tumor.
- Mayor complejidad visual en la imagen.

Esto lo convierte en un entorno adecuado para evaluar el comportamiento del pipeline en condiciones más cercanas a un escenario clínico.

3.3. Selección de slices y pacientes

Dado que el objetivo del trabajo es analizar el impacto del submuestreo sobre la segmentación, se ha optado por trabajar con cortes bidimensionales (slices) extraídos de los volúmenes 3D del dataset BraTS.

Para cada paciente, se han seleccionado automáticamente aquellos slices que contienen información relevante del tumor, concretamente:

- Se han identificado todos los cortes con presencia de píxeles tumorales.
- Se han elegido hasta tres slices representativos, considerando:
 - uno con alta carga tumoral,
 - uno con carga intermedia,
 - y uno con menor presencia de tumor.

Este enfoque permite analizar distintos niveles de dificultad dentro de un mismo paciente sin aumentar excesivamente la complejidad computacional.

Además, el estudio se ha extendido a varios pacientes, con el objetivo de evaluar la consistencia de los resultados y evitar conclusiones basadas en un único caso.

3.4. Entorno y librerías empleadas

El desarrollo del proyecto se ha realizado en un entorno de programación basado en Python, utilizando un notebook interactivo que permite integrar código, visualizaciones y análisis de resultados.

Las principales librerías empleadas han sido:

- NumPy, para el manejo de arrays y operaciones numéricas.
- Matplotlib, para la visualización de imágenes y resultados.
- scikit-image, para la generación del fantoma de Shepp-Logan.
- Nibabel, para la carga de volúmenes médicos en formato NIfTI.
- PyTorch, como backend para la ejecución del modelo de segmentación.
- Transformers (HuggingFace), para la carga y uso del modelo MedSAM.

Este conjunto de herramientas permite implementar de forma eficiente todas las fases del pipeline, desde la simulación en espacio-k hasta la segmentación y evaluación cuantitativa.

4. Diseño general del pipeline

4.1. Descripción global del flujo de trabajo

El flujo de trabajo se estructura en varias fases consecutivas, que transforman una imagen de entrada hasta obtener métricas cuantitativas de rendimiento. De forma general, el pipeline sigue los siguientes pasos:

1. Selección y preprocesado de la imagen de entrada.
2. Transformación al dominio de frecuencias (espacio-k).
3. Aplicación de distintas estrategias de submuestreo.
4. Reconstrucción de la imagen en el dominio espacial.
5. Segmentación mediante el modelo MedSAM.
6. Evaluación cuantitativa de la segmentación mediante el coeficiente Dice.

Este diseño permite estudiar de forma controlada cómo las decisiones en la fase de adquisición (submuestreo) afectan al resultado final de segmentación.

4.2. Fase 1: Validación técnica inicial sobre Shepp-Logan

En una primera fase, el pipeline se valida utilizando el fantoma de Shepp-Logan, una imagen sintética que permite trabajar en un entorno controlado.

El objetivo de esta fase no es obtener resultados clínicamente relevantes, sino asegurar el correcto funcionamiento de los distintos componentes del sistema. En particular, se comprueba:

- La correcta transformación de la imagen al espacio-k mediante FFT.
- La aplicación de máscaras de submuestreo sobre el espacio de frecuencias.
- La reconstrucción de la imagen mediante IFFT.
- El comportamiento visual de las distintas estrategias de submuestreo.

Esta fase permite detectar posibles errores en la implementación antes de trabajar con datos reales, donde la interpretación de los resultados es más compleja.

4.3. Fase 2: Generación de escenarios de submuestreo

Una vez validado el pipeline básico, se introducen distintas estrategias de submuestreo del espacio-k con el fin de simular escenarios de adquisición acelerada.

En esta fase se consideran tres tipos principales de submuestreo:

- Submuestreo cartesiano uniforme, donde se seleccionan líneas del espacio-k de forma periódica.
- Submuestreo cartesiano no uniforme, donde se priorizan las regiones de bajas frecuencias.

- Submuestreo tipo Partial Fourier, en el que solo se adquiere una fracción continua del espacio-k.

Para cada estrategia, se generan distintos niveles de aceleración, representados por el factor R , lo que permite analizar el efecto de una mayor o menor pérdida de información.

El resultado de esta fase es un conjunto de imágenes reconstruidas bajo diferentes condiciones de adquisición, que servirán como entrada para la etapa de segmentación.

4.4. Fase 3: Validación de segmentación en BraTS 2020

Tras validar el pipeline en un entorno sintético, se introduce el dataset BraTS 2020 para trabajar con imágenes médicas reales.

En esta fase se selecciona una slice representativa de un volumen de resonancia magnética que contiene tumor, junto con su correspondiente máscara de referencia. A partir de esta información:

- Se genera un prompt de tipo caja (box prompt) basado en la localización del tumor.
- Se aplica el modelo MedSAM sobre la imagen original, obteniendo una segmentación base.
- Se evalúa esta segmentación respecto a la máscara real mediante el coeficiente Dice.

El objetivo de esta fase es comprobar que el modelo de segmentación produce resultados razonables sobre datos reales antes de analizar el efecto del submuestreo.

4.5. Fase 4: Análisis multi-slice y multi-paciente

Finalmente, el pipeline se extiende para incluir múltiples slices y varios pacientes del dataset BraTS.

En lugar de limitar el análisis a un único caso, se seleccionan varias slices representativas por paciente, con el fin de capturar distintos niveles de complejidad en la segmentación. Este proceso se repite en varios pacientes, lo que permite evaluar la consistencia de los resultados.

Para cada slice y cada escenario de submuestreo, se realiza:

- La reconstrucción de la imagen a partir del espacio-k submuestreado.
- La segmentación mediante MedSAM utilizando el mismo prompt.
- El cálculo de métricas cuantitativas de solapamiento.

Los resultados se organizan y agregan para obtener una visión global del comportamiento del sistema, lo que permite identificar patrones consistentes y analizar la variabilidad entre casos.

5. Implementación del pipeline

5.1. Carga y preprocesado de imágenes

El pipeline comienza con la carga de las imágenes de entrada, tanto del fantoma de Shepp-Logan como del dataset BraTS 2020.

En el caso del fantoma, la imagen se genera directamente en memoria mediante herramientas específicas de procesamiento de imagen. Para el dataset BraTS, se utilizan volúmenes en formato NIfTI, que se cargan mediante librerías especializadas.

Una vez cargadas las imágenes, se realiza un preprocesado básico que incluye:

- Conversión a formato numérico adecuado para su manipulación.
- Normalización de intensidades al rango $[0, 1]$, con el fin de homogeneizar la entrada al modelo de segmentación.
- Selección de slices bidimensionales a partir de volúmenes 3D en el caso de BraTS.

Este preprocesado asegura que todas las imágenes sean comparables y puedan ser utilizadas de forma consistente en las etapas posteriores del pipeline.

5.2. Transformación al espacio-k

A partir de la imagen preprocesada, se realiza la transformación al dominio de frecuencias mediante la aplicación de la FFT (descrita en la Sección 2.3).

Para facilitar la interpretación visual del espacio-k, se emplea una versión centrada de la transformada, de forma que las bajas frecuencias se sitúan en la región central de la representación. Esta organización resulta especialmente útil para aplicar posteriormente las máscaras de submuestreo.

El resultado de esta etapa es una representación completa del espacio-k asociada a cada imagen de entrada.

5.3. Generación de máscaras de submuestreo

Una vez obtenido el espacio-k, se generan distintas máscaras binarias que determinan qué posiciones serán muestreadas y cuáles serán descartadas.

Estas máscaras se construyen de acuerdo con las estrategias descritas en la Sección 2.2, adaptadas a la resolución de la imagen. En todos los casos, las máscaras mantienen la misma dimensión que el espacio-k y contienen valores binarios que indican si una determinada posición es conservada o anulada.

5.3.1. Submuestreo cartesiano uniforme

En este caso, la máscara se genera seleccionando líneas del espacio-k de forma periódica a lo largo de una de las dimensiones. El patrón de muestreo viene determinado por el factor de aceleración R , de modo que se conserva una de cada R líneas.

Este tipo de submuestreo produce una distribución regular de muestras en el espacio de frecuencias.

5.3.2. Submuestreo cartesiano no uniforme

Para el submuestreo no uniforme, se define una región central del espacio-k donde se conservan todas las muestras, mientras que en las regiones exteriores se aplica un patrón de muestreo periódico similar al caso uniforme.

Este diseño permite priorizar las bajas frecuencias, que contienen la información estructural principal de la imagen, reduciendo al mismo tiempo el número total de muestras

5.3.3. Partial Fourier

En el caso de Partial Fourier, la máscara se construye conservando únicamente una fracción continua del espacio-k a lo largo de una de sus dimensiones, eliminando el resto de las muestras.

Esta estrategia reduce el número de datos adquiridos manteniendo una estructura coherente en el dominio de frecuencias, aunque implica una pérdida directa de información en una parte del espectro

5.4. Reconstrucción de imágenes submuestreadas

Las máscaras generadas se aplican directamente sobre el espacio-k completo mediante una operación de producto elemento a elemento.

A continuación, se reconstruye la imagen en el dominio espacial utilizando la IFFT (Sección 2.3). El resultado de esta reconstrucción corresponde a la imagen que se obtendría tras una adquisición acelerada bajo la estrategia de submuestreo considerada.

Para cada imagen original, se generan múltiples reconstrucciones correspondientes a los distintos tipos de submuestreo y factores de aceleración, lo que permite comparar su impacto de forma sistemática.

5.5. Generación de prompts para MedSAM

La segmentación mediante MedSAM requiere la definición de un prompt que indique la región de interés dentro de la imagen.

En este trabajo, se utiliza un box prompt, generado automáticamente a partir de la máscara de referencia del tumor en las imágenes de BraTS. Este proceso consiste en calcular el rectángulo delimitador mínimo que contiene la región tumoral.

Para cada slice, se define un único prompt, que se mantiene constante en todos los escenarios de submuestreo. Esta decisión permite aislar el efecto de la degradación de la imagen sin introducir variabilidad adicional en la entrada del modelo.

5.6. Segmentación con MedSAM

La segmentación se realiza utilizando el modelo MedSAM, cargado mediante la librería Transformers y ejecutado sobre PyTorch.

Para cada imagen reconstruida:

- Se adapta el formato de la imagen al requerido por el modelo.
- Se introduce el prompt previamente definido.
- Se obtiene como salida una máscara binaria que representa la segmentación generada.

Este proceso se aplica de forma consistente a todas las imágenes, tanto originales como reconstruidas, garantizando la comparabilidad de los resultados.

5.7. Cálculo del coeficiente Dice

La evaluación de las segmentaciones se realiza mediante el coeficiente Dice (definido en la Sección 2.6).

En este trabajo se consideran dos comparaciones distintas:

- Dice respecto a la máscara real (ground truth), que mide la fidelidad de la segmentación respecto a la anotación manual.
- Dice respecto a la segmentación obtenida en la imagen original, que permite evaluar la estabilidad del modelo frente a degradaciones en la imagen.

Ambas métricas se calculan para cada combinación de slice y escenario de submuestreo.

5.8. Organización experimental del código y automatización de pruebas

Con el fin de facilitar la repetición de experimentos y el análisis de resultados, el pipeline se ha estructurado de forma modular.

Se han definido funciones específicas para cada etapa del proceso, incluyendo:

- Preprocesado de imágenes.
- Generación de máscaras.
- Reconstrucción.
- Segmentación.
- Cálculo de métricas.

Estas funciones se integran en un flujo automatizado que permite ejecutar el pipeline completo sobre múltiples slices y pacientes de forma sistemática.

Los resultados se almacenan en estructuras de datos organizadas, lo que facilita su posterior análisis y visualización.


6. Desarrollo experimental

6.1. Experimento 1: integración del pipeline en Shepp-Logan

El primer experimento se centra en la validación inicial del pipeline utilizando el fantoma de Shepp-Logan.

En esta etapa, se aplica el flujo completo de transformación al espacio-k y reconstrucción mediante IFFT sin introducir submuestreo. El objetivo es comprobar que la imagen reconstruida coincide con la imagen original, validando así el correcto funcionamiento de las transformaciones implementadas.

Este experimento permite asegurar que la base del pipeline es correcta antes de introducir degradaciones en el proceso de adquisición.



6.2. Experimento 2: efecto visual del submuestreo en Shepp-Logan

Una vez validada la transformación y reconstrucción, se introducen distintas estrategias de submuestreo sobre el espacio-k del fantoma de Shepp-Logan.

Para cada tipo de submuestreo (uniforme, no uniforme y Partial Fourier) y para distintos factores de aceleración, se generan imágenes reconstruidas a partir del espacio-k incompleto.

El objetivo de este experimento es analizar de forma cualitativa cómo afectan estas estrategias a la apariencia de la imagen, observando fenómenos como:

- aparición de aliasing en submuestreo uniforme,
- pérdida progresiva de detalle en función del factor de aceleración,
- diferencias visuales entre los distintos tipos de submuestreo.

Este análisis permite validar el comportamiento esperado del sistema en un entorno controlado.

6.3. Experimento 3: validación base de MedSAM sobre una slice BraTS original

Tras la validación en datos sintéticos, se introduce el dataset BraTS 2020 para evaluar el comportamiento del modelo de segmentación en imágenes reales.

En este experimento se selecciona una única slice representativa de un volumen que contiene tumor. A partir de esta slice:

- Se genera la máscara binaria de referencia (ground truth).
- Se construye un prompt de tipo caja a partir de dicha máscara.
- Se aplica el modelo MedSAM sobre la imagen original.

El objetivo es obtener una segmentación base y evaluar su calidad mediante el coeficiente Dice respecto a la máscara real.

Este paso es necesario para comprobar que el modelo produce resultados razonables antes de analizar el efecto del submuestreo.

6.4. Experimento 4: impacto del submuestreo en una slice BraTS

Una vez validada la segmentación sobre la imagen original, se estudia el efecto del submuestreo sobre una única slice de BraTS.

Para ello, se aplica el pipeline completo:

- Transformación de la imagen al espacio-k.
- Aplicación de las distintas máscaras de submuestreo.
- Reconstrucción de cada caso mediante IFFT.
- Segmentación de cada imagen reconstruida utilizando el mismo prompt definido previamente.

Se calculan dos métricas de evaluación:

- Dice respecto a la máscara real.
- Dice respecto a la segmentación obtenida en la imagen original.

Este experimento permite analizar cómo cambian las segmentaciones al introducir degradaciones en la imagen de entrada.

6.5. Experimento 5: extensión a múltiples slices del mismo paciente

Con el fin de evitar conclusiones basadas en una única slice, el análisis se amplía a varias slices del mismo paciente.

Se seleccionan automáticamente varias slices representativas con presencia de tumor, y se repite el experimento anterior para cada una de ellas.

El objetivo es evaluar la consistencia de los resultados dentro de un mismo caso clínico, teniendo en cuenta que la dificultad de segmentación puede variar en función de la localización y extensión del tumor.

Los resultados obtenidos se organizan en tablas y se agregan para facilitar su interpretación.

6.6. Experimento 6: análisis multi-paciente

Finalmente, el experimento se extiende a varios pacientes del dataset BraTS.

Para cada paciente:

- Se seleccionan varias slices con presencia de tumor.
- Se aplica el pipeline completo de reconstrucción y segmentación.
- Se calculan las métricas correspondientes para cada caso.

Posteriormente, los resultados se agregan considerando todos los pacientes y slices, obteniendo medidas globales como la media y la desviación estándar del coeficiente Dice.

Este experimento permite evaluar la robustez del sistema y analizar si los patrones observados se mantienen en diferentes casos clínicos o dependen de características específicas de cada paciente.

7. Resultados

7.1. Resultados cualitativos de reconstrucción

En primer lugar, se analizan los resultados visuales obtenidos tras aplicar las distintas estrategias de submuestreo y reconstrucción.

Sobre el fantoma de Shepp-Logan, se observa que:

- El submuestreo cartesiano uniforme introduce artefactos periódicos visibles en forma de aliasing.
- El submuestreo no uniforme preserva mejor la estructura global de la imagen, especialmente en las regiones centrales.
- El enfoque Partial Fourier produce una degradación más suave, asociada a la pérdida de información en una parte del espacio-k.

Estos resultados cualitativos confirman el comportamiento esperado de cada estrategia en un entorno controlado.




Figura 1




Figura 2.

Como se observa en la Figura 1, las distintas estrategias de submuestreo producen efectos claramente diferenciados en la imagen reconstruida. Asimismo, en la Figura 2 se muestran las máscaras de submuestreo utilizadas, lo que permite interpretar visualmente el origen de estas diferencias.

7.2. Resultados cualitativos de segmentación

En el caso de las imágenes del dataset BraTS, se comparan visualmente las segmentaciones obtenidas por MedSAM sobre:

- la imagen original,
- las imágenes reconstruidas tras submuestreo uniforme,
- las imágenes reconstruidas tras submuestreo no uniforme,
- y las obtenidas mediante Partial Fourier.

Se observa que las máscaras generadas varían en función de la calidad de la imagen de entrada, mostrando diferencias en:

- el contorno de la región segmentada,
- la presencia de fragmentación en la máscara,
- y la extensión de la región detectada.

Estas diferencias se analizan posteriormente de forma cuantitativa.




Figura 3




Figura 4




Figura 5

En la Figura 3 se presenta un ejemplo representativo de segmentación bajo distintos escenarios de submuestreo. Asimismo, las Figuras 4 y 5 muestran casos adicionales con diferente complejidad, lo que permite observar la variabilidad en el comportamiento del modelo.

7.3. Resultados cuantitativos en Shepp-Logan

El cálculo del coeficiente Dice sobre el fantoma de Shepp-Logan no presenta valores significativos para la evaluación de segmentación, ya que se trata de un entorno sintético sin una estructura anatómica real claramente definida para este propósito.

Por este motivo, los resultados en Shepp-Logan se utilizan principalmente como validación técnica del pipeline, y no como base para conclusiones cuantitativas sobre segmentación.

7.4. Resultados cuantitativos en BraTS: una slice

En una primera aproximación, se analiza una única slice de BraTS, comparando el rendimiento de la segmentación en función del tipo de submuestreo y del factor de aceleración.

Se obtienen valores del coeficiente Dice tanto respecto a la máscara real como respecto a la segmentación obtenida en la imagen original.

Los resultados muestran variaciones en el rendimiento de la segmentación en función del escenario considerado, lo que evidencia la sensibilidad del modelo a las condiciones de adquisición.

case_name	mean_Dice_vs_GT	std_Dice_vs_GT	mean_Dice_vs_OriginalMedSAM	std_Dice_vs_OriginalMedSAM
full	0.569578	0.203660	1.000000	0.000000
uniform_R2	0.640156	0.243581	0.612815	0.258282
uniform_R4	0.627730	0.207212	0.590219	0.199306
uniform_R8	0.493557	0.171951	0.516099	0.217381
nonuniform_R2	0.729594	0.134180	0.644224	0.218412
nonuniform_R4	0.647113	0.212648	0.620937	0.218783
nonuniform_R8	0.680441	0.096552	0.624480	0.251725
partial fourier	0.659918	0.211579	0.606740	0.252703

7.5. Resultados cuantitativos en BraTS: múltiples slices

El análisis se amplía posteriormente a varias slices del mismo paciente, lo que permite observar la variabilidad de los resultados dentro de un mismo caso clínico.

Los valores del coeficiente Dice presentan diferencias entre slices, lo que indica que la calidad de la segmentación depende no solo del tipo de submuestreo, sino también de las características específicas de cada corte, como la extensión y forma del tumor.

7.6. Resultados globales multi-paciente

Finalmente, se agregan los resultados obtenidos en múltiples pacientes y slices, calculando valores medios y desviaciones estándar para cada escenario de submuestreo.

De forma general, se observan las siguientes tendencias:

- Los valores de Dice varían entre pacientes y slices, reflejando una alta variabilidad en el comportamiento del modelo.
- Los escenarios de submuestreo no uniforme con factores de aceleración moderados presentan, en promedio, valores elevados de Dice respecto a la máscara real.
- El submuestreo uniforme con factores de aceleración altos tiende a mostrar un descenso en el rendimiento.
- El método Partial Fourier presenta resultados intermedios entre los distintos enfoques.

Estos resultados globales permiten confirmar que el comportamiento observado no es específico de un único caso, sino que se mantiene de forma consistente en múltiples pacientes.

7.7. Comparación entre Dice respecto a GT y dice respecto a la segmentación original de MedSAM




Figura 6




Figura 7

Método	Mean Dice (GT)	Std (GT)	Mean Dice (Orig)	Std (Orig)
full	0.57	0.19	1.00	0.00
uniform_R2	0.64	0.21	0.63	0.24
uniform_R4	0.63	0.21	0.64	0.19
uniform_R8	0.49	0.16	0.59	0.20
nonuniform_R2	0.73	0.12	0.64	0.20
nonuniform_R4	0.65	0.20	0.62	0.19

Método	Mean Dice (GT)	Std (GT)	Mean Dice (Orig)	Std (Orig)
nonuniform_R8	0.68	0.13	0.64	0.23
partial_fourier	0.66	0.20	0.61	0.23

Los resultados agregados muestran que el submuestreo no uniforme con factor de aceleración $R=2$ presenta, en promedio, los mayores valores de Dice respecto a la máscara real. Sin embargo, la desviación estándar indica una variabilidad significativa entre casos, lo que sugiere que el comportamiento del modelo depende de las características específicas de cada slice. Además, no se observa una relación monótona entre el nivel de submuestreo y la calidad de la segmentación, lo que refuerza la complejidad del fenómeno analizado.

Se han considerado dos métricas de evaluación distintas:

- Dice respecto a la máscara real (ground truth).
- Dice respecto a la segmentación obtenida en la imagen original.

La comparación entre ambas métricas muestra que:

- El coeficiente Dice respecto a la segmentación original tiende a disminuir en todos los escenarios de submuestreo, indicando cambios en la salida del modelo.
- El coeficiente Dice respecto a la máscara real presenta un comportamiento más variable, dependiendo del caso y del tipo de submuestreo.

Esta diferencia pone de manifiesto que ambas métricas capturan aspectos distintos del rendimiento del sistema.

8. Discusión

8.1. Influencia del submuestreo en la reconstrucción

Los resultados cualitativos obtenidos sobre el fantoma de Shepp-Logan muestran que las distintas estrategias de submuestreo afectan de manera significativa a la imagen reconstruida.

En el caso del submuestreo cartesiano uniforme, se observan artefactos de aliasing claramente estructurados, lo que indica una pérdida de información distribuida de forma periódica en el espacio de frecuencias. Por otro lado, el submuestreo no uniforme preserva mejor la estructura global de la imagen, lo que sugiere que la priorización de bajas frecuencias permite mantener las características principales de la escena.

El enfoque Partial Fourier, al eliminar una porción continua del espacio-k, produce una degradación más homogénea, sin introducir patrones periódicos tan evidentes, pero con una pérdida global de información.

Estos comportamientos son coherentes con la forma en que cada estrategia selecciona la información en el dominio de frecuencias y constituyen la base para entender su impacto posterior en la segmentación.

8.2. Influencia del submuestreo en la segmentación

El análisis cuantitativo realizado sobre el dataset BraTS confirma que el submuestreo del espacio-k tiene un impacto significativo en la segmentación generada por MedSAM.

Al comparar las segmentaciones obtenidas a partir de imágenes submuestreadas con la segmentación original (sin degradación), se observa una disminución general del coeficiente Dice, lo que indica que las modificaciones introducidas en la imagen afectan directamente al comportamiento del modelo.

Este resultado valida la hipótesis de que la calidad de la imagen de entrada es un factor determinante en el rendimiento de los modelos de segmentación, incluso cuando estos modelos están diseñados para ser robustos a variaciones visuales.

8.3. Comportamientos no monótonos observados

Uno de los resultados más relevantes del estudio es la ausencia de una relación monótona clara entre el nivel de submuestreo y la calidad de la segmentación.

Aunque en algunos casos un aumento del factor de aceleración conlleva una disminución del coeficiente Dice, en otros se observan situaciones en las que configuraciones con mayor submuestreo presentan valores superiores a configuraciones menos agresivas.

Este comportamiento no monótono se observa tanto entre distintos factores de aceleración como entre diferentes estrategias de submuestreo, lo que indica que la relación entre degradación de la imagen y rendimiento del modelo no es lineal.

Este resultado pone de manifiesto la complejidad del problema y sugiere que no es posible establecer una regla general simple que relacione directamente el nivel de submuestreo con la calidad de la segmentación.

8.4. Posible efecto de regularización por pérdida de alta frecuencia

El análisis de los resultados muestra que, en determinados casos, las imágenes reconstruidas a partir de datos submuestreados presentan valores de Dice respecto a la máscara real superiores a los obtenidos con la imagen original.

Este fenómeno puede interpretarse como un efecto de regularización inducido por la pérdida de información de alta frecuencia. La eliminación de detalles finos y ruido estructural puede dar lugar a imágenes más suaves, lo que facilita la generación de máscaras más compactas por parte del modelo.

Como consecuencia, la segmentación puede presentar un mayor solapamiento con la máscara de referencia en ciertos casos, especialmente cuando la segmentación original contiene irregularidades o fragmentación.

No obstante, este efecto no se observa de forma consistente en todos los casos, lo que indica que su aparición depende de las características específicas de la imagen y del tumor.

8.5. Diferencias entre submuestreo uniforme, no uniforme y partial Fourier

El análisis agregado de múltiples slices y pacientes permite identificar diferencias en el comportamiento de las distintas estrategias de submuestreo.

En general, el submuestreo no uniforme con factores de aceleración moderados presenta un comportamiento más estable, manteniendo valores de Dice relativamente elevados en comparación con otras configuraciones.

Por otro lado, el submuestreo uniforme con factores de aceleración altos tiende a degradar de forma más significativa la calidad de la segmentación, lo que es coherente con la aparición de artefactos estructurados en la imagen reconstruida.

El enfoque Partial Fourier se sitúa en una posición intermedia, mostrando un comportamiento más homogéneo, pero con resultados variables en función del caso.

Estas diferencias reflejan la importancia de la estrategia de adquisición en el rendimiento final del sistema.

8.6. Variabilidad entre slices y pacientes

La extensión del análisis a múltiples slices y pacientes pone de manifiesto una variabilidad significativa en los resultados.

Se observa que:

- El rendimiento del modelo depende de la slice considerada, incluso dentro del mismo paciente.
- Existen diferencias notables entre pacientes, asociadas a la forma, tamaño y localización del tumor.
- La variabilidad es especialmente alta en slices con menor presencia tumoral o estructuras más complejas.

Este resultado indica que el impacto del submuestreo no es uniforme y depende en gran medida del contexto anatómico.

Desde un punto de vista práctico, esto sugiere que las conclusiones obtenidas a partir de un único caso pueden no ser representativas, justificando la necesidad de un análisis multi-paciente.

8.7. Limitaciones del estudio

A pesar de los resultados obtenidos, el presente trabajo presenta varias limitaciones que deben tenerse en cuenta:

- El análisis se ha realizado sobre un número reducido de pacientes y slices, lo que limita la generalización de los resultados.
- Se ha trabajado con imágenes bidimensionales, sin considerar la información volumétrica completa.
- El modelo MedSAM se ha utilizado sin ajuste específico para el dataset considerado.
- Se ha utilizado un único tipo de prompt (box prompt), sin explorar otras alternativas.

Estas limitaciones no invalidan los resultados, pero sí condicionan su interpretación y abren la puerta a futuras mejoras.

9. Conclusiones

9.1. Conclusiones principales

En este trabajo se ha desarrollado un pipeline completo para analizar el impacto del submuestreo del espacio-k en la segmentación de imágenes de resonancia magnética mediante el modelo MedSAM.

Los resultados obtenidos permiten extraer las siguientes conclusiones principales:

- El submuestreo del espacio-k tiene un impacto significativo en la segmentación generada por el modelo, alterando la salida incluso en escenarios de aceleración moderada.
- La relación entre el nivel de submuestreo y la calidad de la segmentación no es monótona, observándose comportamientos no lineales en función del tipo de submuestreo y de las características de la imagen.
- En determinados casos, las imágenes reconstruidas a partir de datos submuestreados presentan valores de Dice superiores a los obtenidos con la imagen original, lo que sugiere la existencia de un posible efecto de regularización asociado a la pérdida de alta frecuencia.
- El submuestreo no uniforme con factores de aceleración moderados muestra, en promedio, un comportamiento más estable en comparación con otras estrategias.
- Existe una variabilidad considerable en los resultados entre slices y pacientes, lo que indica que el efecto del submuestreo depende del contexto anatómico y no puede generalizarse de forma directa.

9.2. Respuesta a los objetivos planteados

El objetivo general del trabajo, consistente en analizar el impacto del submuestreo del espacio-k en la segmentación mediante MedSAM, ha sido alcanzado mediante la implementación y evaluación del pipeline propuesto.

En particular:

- Se ha implementado un sistema completo de transformación, submuestreo y reconstrucción de imágenes de resonancia magnética.
- Se han aplicado distintas estrategias de submuestreo y se ha evaluado su impacto sobre la segmentación.
- Se ha cuantificado el rendimiento mediante el coeficiente Dice, considerando tanto la comparación con la máscara real como con la segmentación original.
- Se ha extendido el análisis a múltiples slices y pacientes, permitiendo evaluar la consistencia de los resultados.

9.3. Líneas futuras de trabajo

A partir de los resultados obtenidos, se identifican varias líneas de trabajo que podrían ampliar el alcance de este estudio:

- Incrementar el número de pacientes y slices analizados para mejorar la robustez estadística de los resultados.
- Extender el análisis a segmentación volumétrica en 3D, aprovechando la información completa de los estudios de resonancia magnética.
- Evaluar el comportamiento de otros modelos de segmentación y comparar su sensibilidad al submuestreo.
- Explorar el uso de distintos tipos de prompts en MedSAM, como puntos o combinaciones de señales de guía.
- Investigar técnicas de reconstrucción más avanzadas que puedan mitigar los efectos del submuestreo.

10. Bibliografía

- [1] M. Lustig, D. Donoho, y J. M. Pauly, “Sparse MRI: The application of compressed sensing for rapid MR imaging,” *Magnetic Resonance in Medicine*, vol. 58, no. 6, pp. 1182–1195, 2007
- [2] K. P. Pruessmann et al., “SENSE: Sensitivity encoding for fast MRI,” *Magnetic Resonance in Medicine*, vol. 42, no. 5, pp. 952–962, 1999.
- [3] O. Ronneberger, P. Fischer, y T. Brox, “U-Net: Convolutional networks for biomedical image segmentation,” en *MICCAI*, 2015.
- [4] A. Kirillov et al., “Segment Anything,” *arXiv preprint arXiv:2304.02643*, 2023.
- [5] MedSAM Team, “MedSAM: Segment Anything in Medical Images,” 2023.
- [6] B. Menze et al., “The Multimodal Brain Tumor Image Segmentation Benchmark (BraTS),” *IEEE Transactions on Medical Imaging*, 2015.
- [7] BraTS 2020 Dataset, CBICA, University of Pennsylvania.
Disponible en: <https://www.med.upenn.edu/cbica/brats2020/data.html>
- [8] J. S. Shepp y B. F. Logan, “The Fourier reconstruction of a head section,” *IEEE Transactions on Nuclear Science*, 1974.
- [9] NumPy Developers, “NumPy documentation,” <https://numpy.org>
- [10] PyTorch Team, “PyTorch documentation,” <https://pytorch.org>
- [11] HuggingFace, “Transformers library,” <https://huggingface.co/docs/transformers>
- [12] NiBabel Developers, “NiBabel documentation,” <https://nipy.org/nibabel/>